

Universidade de Aveiro-DETI

Ano Letivo 25/26

Feed de Notícias Inteligente e Personalizado

*Métodos Probabilísticos para Engenharia Informática
(MPEI)*

Autores do Trabalho:

David Monteiro (125793)

Murilo Frezzato (125487)

1. Introdução e Resumo Executivo

O presente relatório descreve o desenvolvimento, a validação experimental e a integração de um pipeline de software inteligente aplicado à triagem, classificação temática e remoção de fluxos massivos de informação duplicados (*news feeds*). O sistema foi concebido exclusivamente com recurso a estruturas de dados e algoritmos probabilísticos, de forma a reduzir o consumo de memória RAM e a maximizar o desempenho computacional face a abordagens determinísticas tradicionais.

A arquitetura assenta na cooperação de três grandes módulos implementados em código orientado a objetos no ambiente MATLAB:

1. **Filtro de Bloom (Clássico e de Contadores):** Responsável pelo bloqueio imediato na periferia do sistema de artigos já lidos no histórico do utilizador.
2. **Classificador de Naïve Bayes (Multinomial e Bernoulli):** Responsável pela categorização tópica automática de manchetes (Títulos das Notícias/Headlines) inéditas face às classes nativas do dataset.
3. **MinHash:** Responsável pela análise de similaridade semântica por *shingles*, que impede a exibição de notícias redundantes ou paráfrases dentro da mesma sessão ativa do feed.

Os testes individuais e a demonstração conjunta foram sustentados pelo dataset real **AG News** (*news.csv*). Este dataset contém milhares de manchetes jornalísticas de produção do ano de 2004.

2. Guia de Instalação e Execução do Programa

O código foi estruturado de forma inteiramente modular. O subdiretório **data/** deve conter o ficheiro de dados **news.csv** para assegurar mapeamento correto de caminhos relativos e o funcionamento nativo dos scripts de validação e de treino.

Estrutura Detalhada de Ficheiros e Pastas

- **/data/news.csv** — Ficheiro de dados em bruto contendo as manchetes do dataset AG News.
- **/src/bloomFilter.m** — Classe de instanciação do Filtro de Bloom clássico e por contadores.
- **/src/naiveBayes.m** — Classe do classificador estatístico com suporte a modelação Multinomial e Bernoulli.
- **/src/minHash.m** — Classe do motor de *shingling* e cálculo de assinaturas e matrizes de Jaccard.
- **/tests/test_bloomFilter.m** — Script de validação teórica, *stress-test* e extração empírica do *k* ótimo.

- **/tests/test_naiveBayes.m** — Script de treino cruzado, avaliação de F1-Score e geração da matriz de confusão.
- **/tests/test_minHash.m** — Script de análise de convergência de erro, *speedup* comparativo e sensibilidade de *shingles*.
- **demo_conjunta.m** — Script principal de simulação de streaming do feed inteligente em tempo real.

Instruções de Execução

Para reproduzir integralmente as tabelas estatísticas e as janelas gráficas deste relatório, execute os seguintes comandos diretamente na Janela de Comandos (*Command Window*) do MATLAB na pasta raiz do projeto:

Matlab

% Executar os testes modulares individuais

```
run('tests/test_bloomFilter.m')
```

```
run('tests/test_naiveBayes.m')
```

```
run('tests/test_minHash.m')
```

% Executar a aplicação integrada global

```
run('demo_conjunta.m')
```

3. Apresentação e Análise Crítica dos Resultados Modulares

3.1. Validação Teórica e de Sensibilidade do Módulo Bloom Filter

O guião `test_bloomFilter.m` avaliou o filtro clássico configurado para 1500 títulos do dataset `news.csv`. Para uma taxa teórica de falsos positivos de 10.00%, obteve-se 10.47% real; para 1.00%, obteve-se 2.27% real; e para 0.10%, obteve-se 1.33% real. O construtor força o tamanho m a ser o número primo imediatamente superior para garantir a uniformidade das posições via Kirsch-Mitzenmacher. A contagem de falsos negativos fixou-se estritamente em 0.

O teste do Counting Bloom Filter indicou uma taxa de sucesso de remoção de 98.00% em 100 decrementos controlados de contadores uint16. Na variação empírica com m fixo em 10000 bits, o gráfico da Figura 1 localizou o k ótimo experimental em 4 (taxa mínima de falsos positivos de 0.0827) contra o valor teórico de 5.

Tabela 1: Métricas de Tolerância e Falsos Positivos do Filtro Clássico

Taxa FP Teórica	Espaço Alocado bits	Funções Hash k	Falsos Negativos	Taxa Real FP
0.100	7193	3	0	0.1047

0.010	14387	7	0	0.0227
0.001	21569	10	0	0.0133

3.2. Avaliação de Desempenho e Treino do Módulo Naïve Bayes

O classificador dividiu 2000 documentos na proporção de 70% para treino (1400 documentos) e 30% para teste (600 documentos). A tokenização incluiu filtragem nativa de stopwords para purificar as verosimilhanças com suavização de Laplace add-1. O modelo Multinomial atingiu uma exatidão global de 74.67% contra 61.17% do Bernoulli. O tempo de classificação do Multinomial fixou-se em 0.1490 segundos.

O F1-Score do Multinomial variou entre 0.6348 na classe Economia e 0.7984 na classe Ciência/Tecnologia. As palavras mais relevantes aprendidas foram: najaf e china para Mundo; team e gold para Desporto; oil e stocks para Economia; microsoft e google para Ciência/Tecnologia. O guião gerou a Figura 2 (Matriz de Confusão), expondo maior fricção entre as classes Economia e Ciência/Tecnologia, e a Figura 3 (Curva de Aprendizagem), demonstrando a convergência estável da exatidão global.

Tabela 2: Matriz Comparativa de Modelos Concorrentes

Métrica Analítica	Naïve Bayes Multinomial	Naïve Bayes Bernoulli
Exatidão Global Accuracy	74.67%	61.17%
Tempo de Treino Computacional	0.5076 segundos	0.4519 segundos
Tempo de Classificação	0.1650 segundos	0.3215 segundos

Tabela 3: Desempenho Granular por Categoria de Notícia F1 Score

ID Classe	Nome da Categoria	F1 Score Multinomial	F1 Score Bernoulli
1	Mundo	0.7518	0.6244
2	Desporto	0.7411	0.2906
3	Economia	0.6348	0.4940

4	Ciência / Tecnologia	0.7984	0.6897
---	-------------------------	--------	--------

3.3. Avaliação de Eficiência Computacional e Escala do Módulo MinHash

O módulo MinHash foi testado com 800 manchetes para aferir o erro médio de Jaccard e o ganho de velocidade (speedup) face ao cálculo exato. O método getSignature aplicou a Regra de Horner com módulo iterativo sob um número primo de Mersenne para evitar overflow numérico. O cálculo exato demorou 25.0679 segundos.

Para $k = 50$, o MinHash registou 0.1049 segundos (speedup de 239.0x) e erro de 0.0104. Para $k = 150$, registou 0.2052 segundos (speedup de 122.1x) e erro de 0.0062. O script exportou a Figura 1, ilustrando que o erro decresce à taxa inversamente proporcional à raiz quadrada de k , e a Figura 2 (Histograma de Topologia), mostrando a concentração de distâncias entre 0.95 e 1.0.

O teste de sensibilidade do comprimento do shingle de caracteres indicou: shingle 2 com 571 termos e distância média 0.8990; shingle 3 (ponto ótimo) com 2429 termos e distância 0.9803; shingle 5 com 5710 termos e distância 0.9965. O impacto visual foi representado na Figura 3.

Tabela 4: Análise Paramétrica de Eficiência do Estimador Limiar de Similaridade 0.4

Abordagem Algorítmica	Hashes k	Tempo de Execução	Speedup Relativo	Erro Médio	Pares Detetados
Jaccard Exato	Reais	25.0679 segundos	1.0x	0.0000	44
MinHash Probabilístico	$k = 50$	0.1049 segundos	239.0x	0.0104	54
MinHash Probabilístico	$k = 150$	0.2052 segundos	122.1x	0.0062	55

Tabela 5: Impacto do Comprimento do Shingle na Topologia dos Dados

Tamanho do Shingle	Total de Shingles Únicos	Distância Média de Jaccard Real
2 caracteres	571	0.8990

3 caracteres	2429	0.9803
4 caracteres	4577	0.9925
5 caracteres	5710	0.9965

4. Descrição Detalhada da Aplicação de Uso Conjunto

A aplicação `demo_conjunta.m` executou o pipeline integrado em tempo real sobre um fluxo de 15 cenários mecânicos e dinâmicos gerados a partir do dataset. O pipeline processou cada entrada seguindo a ordem lógica:

- Filtro de Bloom: Consulta o histórico de leitura do utilizador. Se o artigo for correspondência exata, emite um aviso e descarta o conteúdo de forma instantânea para poupar recursos computacionais.
- Estimador MinHash: Com $k = 150$, compara os tri-shingles do texto com os artigos já aceites na sessão corrente. Se a distância de Jaccard for inferior a 0.45, deteta o plágio ou redundância temática e aborta a publicação.
- Naïve Bayes Multinomial: Categoriza a manchete inédita nas quatro gavetas temáticas do feed. Se a confiança calculada for inferior a 60%, ativa um aviso de conteúdo na interface do painel.

A telemetria final acusou 15 artigos submetidos, 2 bloqueados pelo Bloom Filter (Cenários 1 e 2), 3 recusados pelo MinHash por redundância (Cenários 8, 9 e 11, incluindo cópias em maiúsculas e permutações de palavras), e 10 publicados com sucesso (66.7% de entrega líquida). O Cenário 12 ativou o alerta de baixa confiança com 41.29% de probabilidade por ser um texto curto de uma palavra. O sistema exportou a Figura 1 (Gráfico Circular 3D de composição temática) e a Figura 2 (Gráfico de Barras Empilhadas de evolução dinâmica de streaming).

5. Discussão das Vantagens e Limitações do Sistema

5.1. Vantagens Computacionais da Abordagem Probabilística

- Economia de Espaço: O Filtro de Bloom consome um vetor estático de bits, independente do crescimento contínuo do histórico de leitura do utilizador.
- Pesquisa em Tempo Constante: A consulta de pertença opera em complexidade $O(1)$ sem acessos ao disco ou base de dados física.
- Redução de Dimensionalidade: O MinHash comprime textos longos em assinaturas fixas, permitindo comparações matriciais vetorizadas ultrarrápidas, justificadas pelo speedup superior a 120x.
- Proteção contra Sub-fluxo: O Naïve Bayes opera em ambiente logarítmico, eliminando erros de underflow em ponto flutuante.

5.2. Limitações Identificadas e Estratégias de Mitigação

- Falsos Positivos: A possibilidade de colisões que ocultam artigos inéditos foi atenuada pelo uso de tamanhos primos no vetor e pela classe local RandStream para gerar chaves independentes.
- Inabilidade de Remoção: Contornada no ecossistema através do desenvolvimento paralelo do módulo Counting Bloom Filter assente em contadores numéricos de 16 bits.
- Premissa de Independência: O Naïve Bayes ignora a ordem das palavras, mas esta falha foi compensada pelo MinHash, que preserva a estrutura sequencial local através do shingling de caracteres.

6. Conclusão

O ecossistema modular provou ser uma solução de alto rendimento para a gestão inteligente e eliminação de fluxos informativos em tempo real. Os desvios experimentais validaram as propriedades teóricas da cadeira de MPEI, e a cooperação algorítmica garantiu escalabilidade computacional com rigor científico.